

04_FILE_PIPELINE.md

파일 처리 파이프라인

목적

사용자가 업로드한 자료를

AI가 검색 가능한 형태로 변환한다.

지원 파일

문서

pdf
txt
md
docx

음성

mp3
wav
m4a

전체 흐름

파일 업로드

↓

파일 저장

↓

텍스트 추출

↓

문단 분리



청킹



Vector Store 저장



검색 가능

Step 1

파일 업로드

사용자



PDF 선택



Firebase Storage 저장

저장 위치

```
/users/{userId}/bots/{botId}/files
```

Step 2

텍스트 추출

PDF



텍스트 변환

출력

```
{  
  "page":1,  
  "content":"..."  
}
```

Step 3

음성 처리

MP3 업로드

↓

Speech To Text

↓

텍스트 생성

예시

```
안녕하세요.  
오늘은 추상화에 대해...
```

Step 4

문단 분리

긴 문서를

작은 단위로 나눈다.

예시

```
Chunk 1  
Chunk 2  
Chunk 3  
Chunk 4
```

Step 5

청킹 규칙

기본

500~1000자

너무 길면

검색 정확도 하락

Step 6

메타데이터 생성

예시

```
{  
  "documentId": "doc01",  
  "page": 5,  
  "chunk": 12,  
  "source": "gallery-guide.pdf"  
}
```

Step 7

Vector Store 저장

청크 저장

↓

검색 가능 상태

↓

status=indexed

Step 8

질문 처리

사용자 질문

↓

관련 청크 검색

↓

상위 5개 선택

↓

AI 전달

↓

답변 생성

오류 처리

파일 없음

FILE_NOT_FOUND

지원 안함

UNSUPPORTED_FORMAT

텍스트 추출 실패

TEXT_EXTRACTION_FAILED

로그

저장

```
{  
  "botId": "artbot",  
  "documentId": "doc01",  
  "status": "indexed"  
}
```

MVP 기준

PDF 업로드

↓

텍스트 추출

↓

질문

↓

자료 기반 답변

성공하면 MVP 완료